

Projet capstone

Analyse d'une boutique de sport en ligne

Consigne préparée pour Pagui

23 août 2026

Contexte

Tu rejoins l'équipe data d'une boutique en ligne togolaise d'articles de sport. On te confie **5 fichiers** extraits de systèmes différents (site web, CRM, ERP fournisseurs), jamais nettoyés, jamais croisés. Ta mission : les rendre exploitables, puis en tirer des réponses concrètes pour trois services de l'entreprise (direction, marketing, qualité).

Ce projet couvre tout ce que tu as appris jusqu'ici : **pandas (nettoyage, fusion), statistiques descriptives codées, visualisation avec matplotlib/seaborn**. Il s'arrête volontairement **avant le machine learning** – ce sera la suite logique une fois ce projet terminé.

1 Les données

Les 5 fichiers sont dans le dossier `data/`. Ils sont **volontairement sales** – c'est le point du projet, pas un bug.

Fichier	Contenu	Clé
clients.csv	Informations clients	client_id
produits.csv	Catalogue produits	product_id
fournisseurs.csv	Fournisseurs des produits	supplier_id
commandes.csv	Commandes passées en 2025	order_id (+ réf. client/produit)
avis.csv	Avis clients post-livraison	review_id (+ réf. commande)

Dictionnaire des variables

Fichier	Colonne	Description
clients	client_id, nom, age, sexe	identifiant, nom complet, âge, sexe
	ville, date_inscription, segment	ville de résidence, date de création du compte, segment (Nouveau/Régulier/VIP)
produits	category, brand	catégorie (Running, Fitness, Football, Basketball, Yoga, Cyclisme), marque
	cost_price, list_price	prix d'achat et prix de vente (en k FCFA)
	stock_quantity, supplier_id	stock disponible, référence fournisseur
fournisseurs	country, lead_time_days	pays d'origine, délai d'approvisionnement moyen (jours)
	reliability_score	score de fiabilité (0 à 5)
commandes	date, client_id, product_id	date de commande, références client et produit
	quantity, discount_pct	quantité commandée, % de réduction appliqué
	payment_method, region	mode de paiement, région de livraison
	delivery_time_days, status	délai réel de livraison (vide si en cours), statut (Livrée/En cours/Annulée/Retournée)
avis	order_id, rating	référence commande, note laissée (1 à 5)
	comment_length	longueur du commentaire laissé (caractères)

2 Ce qu'on te demande

Le projet est structuré en 4 phases. **Fais-les dans l'ordre** – chaque phase dépend de la précédente, et sauter une étape de nettoyage se paiera cash dans les statistiques et les graphes plus loin.

Attention

Aucun graphe ni aucune méthode n'est indiqué dans les questions ci-dessous : c'est à toi de décider quoi utiliser et pourquoi, comme dans le mini-projet précédent.

Phase 1 – Audit et nettoyage (par fichier)

Pour **chacun des 5 fichiers**, avant de les toucher, fais un audit systématique :

- Combien de valeurs manquantes, dans quelles colonnes ?
- Y a-t-il des doublons (lignes strictement identiques, ou identifiants dupliqués avec des infos différentes) ?
- Les formats sont-ils cohérents dans chaque colonne (dates, texte, casse, espaces) ?
- Y a-t-il des valeurs impossibles ou aberrantes (âge de 180 ans, quantité négative, prix négatif) ?

Ensuite, nettoie chaque fichier :

- Uniformise les formats de date.
- Uniformise les catégories textuelles qui désignent la même chose écrite différemment (villes, modes de paiement, catégories de produits).
- Décide, pour chaque valeur manquante, si tu la supprimes, l'imputes (et avec quoi – moyenne, médiane, mode ? justifie), ou la laisses telle quelle (et pourquoi).
- Traite les valeurs aberrantes : corrige si l'erreur est évidente, exclus si injustifiable, garde si plausible – dans tous les cas, **documente ta décision**.
- Supprime les doublons après les avoir identifiés et compris.

Phase 2 – Fusion des données

Avant de fusionner, réfléchis :

- Certaines commandes référencent des `client_id` ou `product_id` qui n'existent pas dans les autres fichiers. Que fais-tu de ces lignes ? (les supprimer silencieusement peut fausser tes totaux – décide consciemment et documente)
- Certains avis référencent des commandes inexistantes – même question.
- Toutes les commandes n'ont pas d'avis : quel type de jointure utilises-tu selon la question posée (voir Phase 4) ?

Construis une table consolidée exploitable, en conservant la possibilité de revenir aux tables sources si besoin.

Phase 3 – Statistiques descriptives

Calcule et documente, pour les variables numériques clés (prix, délai de livraison, note, âge, quantité) :

- Tendance centrale (moyenne, médiane) et dispersion (écart-type, IQR).
- Compare moyenne et médiane sur chaque variable : sont-elles proches ? Si non, qu'est-ce que ça t'indique sur la forme de la distribution ?

Phase 4 – Exploration graphique et interprétation

Réponds, graphe(s) à l'appui, aux questions suivantes posées par l'entreprise. **Formule d'abord la question en tes propres mots, choisis ensuite le ou les graphes adaptés, puis interprète** – ne te contente jamais d'un graphe sans un paragraphe qui dit ce qu'il montre.

1. **Direction générale** – Le chiffre d'affaires (à calculer à partir de `quantity`, `list_price`, `discount_pct`) évolue-t-il de façon particulière sur l'année ? Y a-t-il des tendances exploitables pour anticiper les stocks ?
2. **Direction générale** – Quelles catégories de produits génèrent le plus de marge (`list_price - cost_price`) ? Est-ce cohérent avec ce qui se vend le plus (`quantity`) ?
3. **Qualité** – Le délai de livraison influence-t-il la note laissée par les clients ? Cette relation est-elle la même dans toutes les régions ?
4. **Qualité** – Les fournisseurs avec un `lead_time_days` élevé ont-ils un impact visible sur le stock ou sur les délais de livraison des produits qu'ils fournissent ?
5. **Marketing** – Le profil des clients VIP (âge, ville, ancienneté) diffère-t-il de celui des clients Nouveaux ? Le mode de paiement varie-t-il selon la région ?
6. **Marketing** – Certains produits ont-ils un stock très déséquilibré par rapport à leurs ventes (sur-stock ou rupture imminente) ?
7. **Direction générale** – Existe-t-il des variables numériques du jeu de données fusionné fortement corrélées entre elles ? Toutes les variables numériques disponibles ont-elles un sens à être incluses dans cette analyse ?

Pour chaque question, sois attentif à ce que ton graphe **ne cache pas** une partie de la réponse (moyenne sans dispersion, proportions avec trop de catégories, variables sans rapport incluses dans une corrélation, etc.).

3 Livrable attendu

Un notebook Jupyter (`.ipynb`) unique, structuré selon les 4 phases ci-dessus, avec :

- du code commenté,
- les graphes produits,
- un paragraphe d'interprétation en Markdown après chaque graphe (le code seul ne suffit pas – un recruteur ou un manager veut lire ta conclusion, pas deviner à partir d'un graphe brut),
- une conclusion générale de quelques lignes en fin de notebook.

4 Auto-évaluation avant de pousser sur GitHub

- ☐ J'ai documenté chaque décision de nettoyage (pas seulement exécuté du code)
- ☐ J'ai géré les valeurs manquantes en justifiant le choix pour chaque colonne concernée
- ☐ J'ai géré les clés orphelines dans les jointures consciemment, pas par accident
- ☐ Chaque graphe répond à une question formulée clairement avant le graphe
- ☐ Chaque graphe est suivi d'une interprétation écrite, pas seulement affiché
- ☐ J'ai vérifié qu'aucun de mes graphes ne cache une partie de la réponse
- ☐ Mon notebook s'exécute de haut en bas sans erreur sur une exécution propre (Kernel -> Restart & Run All)

5 Structure du dépôt suggérée

```
.
|-- README.md
|-- data/
|   |-- clients.csv
|   |-- produits.csv
|   |-- fournisseurs.csv
|   |-- commandes.csv
|   '-- avis.csv
|-- consigne_projet.pdf
'-- notebook_analyse.ipynb    <- ton livrable
```

Ce projet clôture la partie analyse de données de la formation. La suite : machine learning avec scikit-learn.