

Bien choisir et interpréter ses graphes

avec Matplotlib & Seaborn

Cours préparé pour Pagui

23 août 2026

Objectif de ce document

Tu maîtrises déjà l'histogramme et le boxplot. L'enjeu maintenant n'est pas d'apprendre de nouvelles fonctions Python — c'est simple, une ligne suffit à chaque fois — mais d'apprendre à **raisonner** : face à une question posée sur un jeu de données, quel graphe choisir, et une fois le graphe tracé, qu'est-ce qu'il te dit vraiment ?

Ce document est en trois parties :

1. Un **cours** sur chaque type de graphe : explication, quand l'utiliser, comment l'interpréter.
2. Un **quiz** pour vérifier que tu sais choisir le bon graphe selon la situation.
3. Un **mini-projet piège** : un jeu de données e-commerce réel (simulé), des questions posées sans indiquer le graphe à utiliser, volontairement construites pour te faire tomber dans des erreurs classiques – puis une correction détaillée.

Contents

1	Le principe général avant les graphes	3
2	Le cours : un graphe, trois questions	4
2.1	Histogramme (<code>plt.hist</code> / <code>sns.histplot</code>)	4
2.2	Boxplot / boîte à moustaches (<code>sns.boxplot</code>)	4
2.3	Estimation de densité (KDE) (<code>sns.kdeplot</code>)	5
2.4	Diagramme en barres – moyennes (<code>sns.barplot</code>)	6
2.5	Boxplot par catégorie	6
2.6	Violinplot (<code>sns.violinplot</code>)	7
2.7	Nuage de points / Scatter plot (<code>sns.scatterplot</code>)	8
2.8	Courbe d'évolution (<code>sns.lineplot</code>)	8
2.9	Heatmap de corrélation (<code>sns.heatmap</code>)	9
2.10	Pairplot (<code>sns.pairplot</code>)	10
2.11	Countplot (<code>sns.countplot</code>)	11
2.12	Camembert / Pie chart	11
3	Quiz – Choisir le bon graphe	13
4	Mini-projet piège – Analyse d'une boutique de sport en ligne	15

1 Le principe général avant les graphes

Avant de choisir un graphe, pose-toi toujours la même question en trois temps :

1. **Combien de variables je regarde ?** Une seule (distribution) ? Deux (relation) ? Plusieurs à la fois (structure globale) ?
2. **De quel type sont ces variables ?** Numérique continue (prix, âge) ? Catégorielle (région, catégorie de produit) ? Temporelle (date) ?
3. **Quelle question précise je veux qu'il réponde ?** "Comment se répartissent les valeurs ?", "Y a-t-il un lien entre X et Y ?", "Comment ça évolue dans le temps ?", "Quelle est la part de chaque catégorie ?"


Règle d'or

Le graphe n'est jamais une fin en soi. C'est un outil pour répondre à une question précise. Si tu ne sais pas formuler la question en une phrase, tu ne sauras pas choisir le bon graphe. **Formule d'abord la question, choisis le graphe ensuite.**

Ta question	Graphe(s) à envisager
Comment se répartit une seule variable numérique ?	Histogramme, KDE, Boxplot
Je veux comparer une variable numérique entre catégories	Barplot (moyennes), Boxplot/Violinplot (dispersion)
Y a-t-il une relation entre deux variables numériques ?	Scatter plot, Lineplot (si le temps est en jeu)
Comment plusieurs variables sont-elles liées entre elles ?	Heatmap de corrélation, Pairplot
Quelle est la répartition d'une variable catégorielle ?	Countplot, Barplot, (Pie chart si ≤ 4 catégories très distinctes)

2 Le cours : un graphe, trois questions

2.1 Histogramme (`plt.hist` / `sns.histplot`)



L'histogramme découpe l'étendue d'une variable numérique en intervalles (*bins*) et compte combien de valeurs tombent dans chaque intervalle. Il donne une vision globale de la forme de la distribution.


Quand l'utiliser ?

Tu veux voir comment se répartissent les valeurs d'**une seule variable numérique** : est-ce que la majorité des commandes sont autour d'un certain prix ? Y a-t-il un ou plusieurs pics (une seule population ou plusieurs sous-groupes mélangés) ?

Comment l'interpréter ?

Regarde d'abord la **forme générale** : symétrique (en cloche) ou asymétrique (étalée d'un côté, on parle de distribution *skewed*) ? Regarde ensuite s'il y a **un seul pic** (unimodale) ou **plusieurs pics** (bimodale/multimodale – signe possible de sous-groupes différents mélangés dans les données, par exemple deux catégories de produits aux prix très différents). Attention : le nombre de **bins** change complètement l'allure visuelle – toujours tester plusieurs valeurs avant de conclure.

2.2 Boxplot / boîte à moustaches (`sns.boxplot`)



Le boxplot résume une distribution en 5 chiffres clés : le minimum “normal”, le premier quartile (Q1, 25%), la médiane (Q2, 50%), le troisième quartile (Q3, 75%) et le maximum “normal”. Les points isolés au-delà des moustaches sont des **valeurs aberrantes** (outliers).


Quand l'utiliser ?

Tu veux une vue **compacte** de la dispersion et surtout **détecter des valeurs aberrantes** rapidement – ce que l'histogramme fait mal. Très utile aussi pour **comparer plusieurs groupes côte à côte** (une boîte par catégorie).

Comment l'interpréter ?

La **largeur de la boîte** (Q3-Q1, appelée IQR) montre la dispersion de la moitié centrale des données : une boîte large = données très dispersées. La **position de la ligne médiane dans la boîte** montre l'asymétrie : si elle est proche de Q1, la distribution est étalée vers le haut. Les **points isolés** au-delà des moustaches ($1.5 \times \text{IQR}$ au-delà de Q1/Q3, par convention) sont à examiner : erreur de saisie ou vraie valeur extrême ?

2.3 Estimation de densité (KDE) (`sns.kdeplot`)



Le KDE est une version “lissée” de l'histogramme : au lieu de compter les valeurs par intervalle, il estime une courbe de densité continue.


Quand l'utiliser ?

Utile quand tu veux une forme de distribution **plus lisible** que l'histogramme (pas d'effet d'escalier lié aux bins), ou pour **superposer plusieurs distributions** (ex. délai de livraison par région) sans que les barres se chevauchent visuellement.

Comment l'interpréter ?

Même lecture que l'histogramme (pics, symétrie, étalement), mais attention : le KDE peut **créer artificiellement** une impression de valeurs qui n'existent pas (ex. des valeurs négatives pour une variable qui ne peut pas être négative, comme un prix). C'est un lissage mathématique, pas une photographie exacte des données.

2.4 Diagramme en barres – moyennes (sns.barplot)



Le barplot affiche une statistique résumée (par défaut la **moyenne**) d'une variable numérique pour chaque catégorie, avec une barre d'erreur optionnelle.


Quand l'utiliser ?

Tu veux **comparer une valeur moyenne** entre plusieurs groupes/catégories. Exemple typique : le prix moyen par catégorie de produit.

Comment l'interpréter ?

Compare la **hauteur des barres** entre catégories – mais reste prudent : **un barplot cache la dispersion à l'intérieur de chaque catégorie**. Deux catégories peuvent avoir la même moyenne alors que l'une est homogène et l'autre très hétérogène. Regarde toujours la barre d'erreur si elle est affichée – une barre d'erreur large signifie une moyenne peu fiable/représentative.

2.5 Boxplot par catégorie



Le même boxplot que précédemment, mais tracé une fois par catégorie, côte à côte.


Quand l'utiliser ?

Quand tu veux comparer **à la fois** la tendance centrale **et** la dispersion entre plusieurs groupes – c'est souvent un meilleur choix qu'un simple barplot pour une vraie comparaison.

Comment l'interpréter ?

Compare les **médianes** entre catégories (pas les moyennes – le boxplot montre la médiane). Compare aussi la **hauteur des boîtes** : une catégorie avec une boîte large est plus hétérogène qu'une catégorie avec une boîte fine, même si leurs médianes sont proches.

2.6 Violinplot (`sns.violinplot`)



Combine le boxplot (résumé statistique) et le KDE (forme de la distribution) : la largeur du “violin” à chaque hauteur représente la densité de points à cette valeur.


Quand l'utiliser ?

Quand le boxplot ne suffit pas parce que tu soupçonnes une distribution **multimodale** (plusieurs pics) à l'intérieur d'une catégorie – information que le boxplot seul ne montre jamais, puisqu'il résume tout en 5 chiffres.

Comment l'interpréter ?

Regarde la **forme** du violon à chaque catégorie : un violon avec un renflement au milieu = une majorité de valeurs autour de la médiane. Un violon avec deux renflements = deux sous-groupes distincts cachés dans cette catégorie.

2.7 Nuage de points / Scatter plot (`sns.scatterplot`)



Chaque point représente une observation, positionnée selon les valeurs de deux variables numériques (X et Y).


Quand l'utiliser ?

Le graphe **le plus fondamental** pour répondre à la question “existe-t-il une relation entre ces deux variables numériques ?”. Toujours le premier réflexe avant de calculer une corrélation ou d'ajuster un modèle.

Comment l'interpréter ?

Cherche une **tendance visuelle** : le nuage monte (corrélation positive), descend (corrélation négative), ou n'a pas de forme particulière (pas de relation linéaire visible). Regarde aussi si la relation est **linéaire ou non** (une courbe, pas une droite), et repère les **points isolés** loin du nuage principal. Attention à l'**effet de superposition** (overplotting) quand beaucoup de points se chevauchent – utilise alors `alpha=0.3` pour la transparence.

2.8 Courbe d'évolution (`sns.lineplot`)




Relie des points dans un ordre précis, presque toujours pour représenter une **évolution dans le temps** (jour, mois, année).

Quand l'utiliser ?

Dès que l'axe **X** a un **ordre naturel et continu** – typiquement une date. Ne jamais utiliser un **lineplot** pour relier des catégories sans ordre logique (ex. relier “Running” à “Yoga” à “Football” n’a aucun sens, ce ne sont pas des points sur une échelle continue).

Comment l'interpréter ?

Regarde la **tendance générale** (croissance, décroissance, stagnation), les **pics et creux** (saisonnalité – se répètent-ils à intervalles réguliers ?), et les **ruptures brutales** (un événement particulier à cette date ?).

2.9 Heatmap de corrélation (sns.heatmap)

Affiche une matrice de corrélations entre toutes les paires de variables numériques, avec une couleur représentant la force et le sens de la corrélation (souvent de -1 à $+1$).


Quand l'utiliser ?

Dès que tu as **plus de deux variables numériques** et que tu veux repérer rapidement les paires les plus liées entre elles, avant de creuser avec des scatter plots ciblés.

Comment l'interpréter ?

Une valeur proche de **+1** = forte corrélation positive (les deux augmentent ensemble). Proche de **-1** = forte corrélation négative (l’une augmente quand l’autre diminue). Proche de **0** = pas de relation linéaire détectée. **Attention** : corrélation $\neq$ causalité, et une corrélation proche de 0 ne veut pas dire “pas de relation” – seulement “pas de relation *linéaire*”. Une variable comme un identifiant (ID) peut aussi montrer une fausse corrélation si les ID sont attribués dans le temps – toujours se demander si la variable a un sens à être incluse.

2.10 Pairplot (sns.pairplot)



Trace tous les scatter plots possibles entre les paires de variables numériques choisies, avec la distribution de chaque variable sur la diagonale.


Quand l'utiliser ?

Pour une **exploration rapide** en tout début d'analyse, quand tu ne sais pas encore quelles relations chercher entre plusieurs variables numériques. Coûteux à calculer si tu as beaucoup de variables – limite-toi à 4-5 variables maximum.

Comment l'interpréter ?

Parcours chaque case hors diagonale comme un scatter plot classique (relation entre deux variables). Sur la diagonale, regarde la forme de distribution de chaque variable seule (comme un histogramme/KDE).

2.11 Countplot (sns.countplot)



Compte automatiquement le nombre d’observations pour chaque catégorie d’une variable catégorielle – c’est un histogramme pour données catégorielles.


Quand l’utiliser ?

Dès que tu veux répondre à “combien d’observations dans chaque catégorie ?” sans avoir à calculer les comptages toi-même avec `value_counts()`.

Comment l’interpréter ?

Compare directement les **hauteurs de barres**. Vérifie si une catégorie domine largement les autres (déséquilibre des classes – important à savoir avant tout futur modèle de machine learning) et si l’ordre des barres est pertinent (trie-les par fréquence avec `order=...` plutôt que de laisser l’ordre alphabétique par défaut).

2.12 Camembert / Pie chart



Représente chaque catégorie comme une part d’un cercle, proportionnelle à son pourcentage du total.

Quand l’utiliser ?

À utiliser avec parcimonie : uniquement quand tu veux montrer une **proportion par rapport à un tout** (et pas juste comparer des quantités), avec **peu de catégories** (3 à 4 maximum) dont les tailles sont **clairement différentes**.

Comment l'interpréter ?

L'œil humain compare mal les angles/surfaces – c'est la faiblesse fondamentale du camembert. Si deux parts ont une taille proche, il est presque impossible de dire laquelle est la plus grande sans lire les pourcentages affichés. Dès que tu as plus de 4-5 catégories ou des parts de tailles proches, **préfère toujours un barplot ordonné**.

Piège fréquent

Le piège le plus commun en début de formation : utiliser un camembert pour *tout* ce qui est catégoriel, parce que “c'est joli”. En pratique, en data science, le camembert est le graphe le **moins** utilisé par les professionnels – justement parce qu'il communique mal dès qu'il y a plus de 3-4 catégories. Le réflexe correct dans 90% des cas : **countplot ou barplot ordonné**.

3 Quiz – Choisir le bon graphe

Pour chaque situation, identifie le graphe le plus adapté. Les réponses et leurs justifications sont regroupées à la fin de cette section – essaie de répondre à toutes les questions **avant** d’aller voir la correction.

Q1. Tu veux savoir si l’âge des clients est plutôt concentré autour d’une valeur ou très étalé, et si certains âges sont clairement à part du reste.

Q2. Tu veux comparer le nombre moyen d’articles achetés (*quantity*) entre les trois modes de paiement, tout en voyant si cette moyenne est représentative ou cache une forte dispersion.

Q3. Tu veux savoir si le prix d’un article et sa note moyenne sont liés d’une quelconque façon.

Q4. Ton responsable veut un graphe unique montrant l’évolution du chiffre d’affaires jour par jour sur les 12 derniers mois pour repérer les tendances saisonnières.

Q5. Tu as 8 variables numériques dans ton jeu de données et tu veux identifier rapidement, en un seul coup d’œil, les paires les plus fortement liées entre elles avant d’aller plus loin.

Q6. Tu veux montrer combien de commandes proviennent de chacune des 6 régions, en les comparant facilement les unes aux autres.

Q7. Le responsable marketing veut un graphe pour la présentation client montrant que 82% des paiements se font par Mobile Money, 12% par carte et 6% en espèces.

Q8. Tu soupçonnes que les délais de livraison ne suivent pas une seule distribution “normale”, mais qu’il existe en réalité deux populations de clients (livraison rapide en ville, lente en zone rurale), mélangées dans les mêmes données.

Correction

Q1. Histogramme (ou boxplot pour insister sur la détection des valeurs aberrantes). Une seule variable numérique, question sur la forme de la distribution.

Q2. Boxplot ou violinplot par mode de paiement, pas un simple barplot – la question demande explicitement de voir la dispersion, pas seulement la moyenne.

Q3. Scatter plot : deux variables numériques, recherche d’une relation.

Q4. Lineplot : évolution dans le temps, axe X continu et ordonné (les dates).

Q5. Heatmap de corrélation : plus de deux variables numériques, recherche rapide des paires liées.

Q6. Countplot ou barplot : comparaison de quantités entre catégories – surtout pas un pie chart avec 6 parts.

- Q7. Pie chart**, exceptionnellement justifié ici : seulement 3 catégories, avec des parts clairement différentes (82%/12%/6%), et l'objectif est bien de montrer une proportion du tout pour une présentation grand public.
- Q8. Violinplot ou KDE** : le boxplot résumerait tout en 5 chiffres et masquerait la bimodalité (les deux populations mélangées), alors que le violinplot/KDE révèle les deux pics.

4 Mini-projet piège – Analyse d’une boutique de sport en ligne

Contexte

Tu rejoins l’équipe data d’une boutique en ligne togolaise d’articles de sport. Tu reçois un extrait de la base de commandes de l’année 2025 (1080 commandes) avec les colonnes suivantes :

Colonne	Description
order_id	identifiant unique de la commande (attribué dans l’ordre chronologique)
date	date de la commande
category	catégorie du produit (Running, Fitness, Football, Basketball, Yoga, Cyclisme)
region	région togolaise du client (Lomé, Kara, Sokodé, Kpalimé, Atakpamé, Dapaong)
payment_method	mode de paiement (Mobile Money, Carte bancaire, Paiement à la livraison)
price_kfcfa	prix de la commande, en milliers de FCFA
discount_pct	pourcentage de réduction appliqué
quantity	nombre d’articles dans la commande
delivery_time_days	délai de livraison en jours
rating	note laissée par le client (1 à 5, entier)
customer_age	âge du client

Consigne

Pour chaque question ci-dessous, **détermine toi-même** quel(s) graphe(s) utiliser – aucun n’est indiqué, c’est fait exprès. Certaines questions contiennent un piège volontaire : une approche “évidente” te fera tirer une conclusion fausse ou incomplète. Prends le temps de réfléchir à ce que le graphe choisi **cache** avant de conclure. La correction détaillée, avec les figures et l’explication de chaque piège, est à la fin de cette section – n’y va qu’après avoir répondu.

Question 1. Le service financier se demande si le prix des commandes est globalement homogène, ou s’il existe des commandes avec un prix anormalement élevé qu’il faudrait vérifier manuellement (erreur de saisie ou fraude potentielle).

Question 2. La direction logistique veut ajuster ses stocks à l’avance et te demande : “Le nombre de commandes suit-il une tendance particulière au fil de l’année ? Y a-t-il des pics prévisibles ?”

Question 3. Le service produit veut comparer le prix moyen entre les 6 catégories d’articles, mais souhaite aussi savoir si cette moyenne est représentative de chaque catégorie, ou si certaines catégories ont des prix très hétérogènes en interne.

Question 4. Le service qualité pense qu’un délai de livraison plus long fait baisser la note laissée par le client. Comment vérifier cette hypothèse visuellement – et à quel point peux-tu faire confiance à ce que tu vois du premier coup d’œil ?

Question 5. Le service marketing veut savoir si la répartition des modes de paiement est la même dans toutes les régions, ou si certaines régions ont des habitudes de paiement différentes.



Question 6. Le CFO prépare un futur modèle prédictif et te demande d'identifier les variables numériques les plus corrélées entre elles, pour éviter d'en inclure deux qui apportent la même information.

Question 7. Pour un slide de présentation rapide, on te demande un graphe montrant la part de chaque catégorie de produit dans les ventes totales.

Correction détaillée

Correction Question 1


Piège : un histogramme avec des bins par défaut peut totalement masquer quelques valeurs aberrantes – elles sont si peu nombreuses (ici 6 commandes sur 1080) qu’elles n’apparaissent presque pas visuellement, et l’échelle de l’axe X s’étire pour les inclure, ce qui écrase le reste de la distribution et rend le graphe difficile à lire.



Bonne approche : le **boxplot** est spécifiquement conçu pour signaler les valeurs aberrantes comme des points isolés au-delà des moustaches – ici, on voit clairement des commandes à un prix très supérieur au reste, exactement ce que le service financier voulait détecter. L'histogramme seul ne le montre pas clairement à cause de l'échelle.

Correction Question 2



Pas de piège majeur ici si tu as bien identifié qu'il s'agit d'une évolution dans le **temps** : c'est un **lineplot** (agrégé par mois, par exemple), pas un barplot (qui suggérerait des catégories sans ordre) ni un pie chart (qui ne montre aucune évolution).



On observe des pics en mars-avril (rentrée sportive) et novembre-décembre (fêtes), et un creux net en juillet-août – une vraie saisonnalité exploitable pour anticiper les stocks.

Correction Question 3



Piège : un barplot des moyennes par catégorie répond à la première partie de la question, mais **cache totalement** la seconde partie – l'hétérogénéité interne. Deux catégories peuvent avoir des moyennes proches tout en ayant des dispersions très différentes.



Bonne approche : un **violinplot** (ou boxplot) par catégorie répond aux deux parties à la fois : on voit à la fois la tendance centrale et la dispersion/forme de la distribution dans chaque catégorie – ici, le Cyclisme a une distribution bien plus étalée que le Yoga, information invisible sur le barplot seul.

Correction Question 4


Piège double. D’abord, le réflexe scatter plot est correct sur le principe – mais la variable **rating** est **discrète** (seulement 5 valeurs possibles : 1, 2, 3, 4, 5). Un scatter plot classique superpose alors des centaines de points exactement les uns sur les autres, sur seulement 5 lignes horizontales : le nuage a l’air “plein” partout et la vraie tendance devient invisible.



Bonne approche : ajouter un léger bruit aléatoire vertical (*jitter*) et de la transparence ($\alpha=0.25$) révèle enfin la vraie densité de points et confirme visuellement la tendance : plus le délai augmente, plus la densité de points se déplace vers les notes basses. Deuxième piège, plus subtil : une tendance visible sur un scatter plot est une **corrélation**, pas une preuve de **causalité**. D’autres facteurs (la région, par exemple) pourraient influencer à la fois le délai et la note.

Correction Question 5


Piège : avec 6 régions $\times$ 3 modes de paiement, ça fait 18 combinaisons. Un camembert avec 18 parts est totalement illisible – c’est l’erreur typique de vouloir tout montrer sur un seul graphe simple alors que la question porte en réalité sur **deux variables catégorielles croisées**.



Bonne approche : un **tableau croisé** (`pd.crosstab`) affiché comme **heatmap** montre en un coup d’œil les comptages pour chaque combinaison région/paiement, avec la couleur qui fait immédiatement ressortir les cases fortes – ici, Mobile Money domine partout, mais on repère facilement si une région se distingue par un usage plus fort du paiement à la livraison.

Correction Question 6

Piège : si tu inclus `order_id` dans la heatmap de corrélation (une erreur facile puisque c’est une colonne numérique comme les autres), tu obtiens une corrélation apparente avec les variables liées au temps – **uniquement parce que les identifiants sont attribués dans l’ordre chronologique**, pas parce qu’il existe un vrai lien entre “être une commande récente” et le prix ou le délai.





Bonne approche : **toujours se demander si une variable a un sens conceptuel** avant de l’inclure dans une analyse de corrélation. Un identifiant n’est pas une grandeur mesurable – il doit être exclu. Une fois retiré, la vraie corrélation intéressante apparaît : **delivery_time_days** et **rating** sont négativement corrélées, ce qui confirme numériquement l’intuition du service qualité de la question 4.

Correction Question 7

Piège : avec 6 catégories dont certaines ont des tailles proches (Running 28%, Fitness 22%, Football 18%...), l’œil humain ne peut pas comparer précisément des angles de camembert

aussi proches – on ne peut pas dire au premier coup d’œil si Fitness est plus grand que Football sans lire les chiffres.

Camembert naïf : parts proches difficiles à comparer



Bonne approche : un **barplot ordonné** (du plus grand au plus petit) permet une comparaison immédiate et précise entre toutes les catégories, même proches en valeur – c’est presque toujours préférable au camembert dès qu’il y a plus de 3-4 catégories, comme vu dans le cours.

Ce qu’il faut retenir de ce mini-projet

- Un graphe “qui marche techniquement” n’est pas forcément un graphe qui répond **correctement et complètement** à la question posée.
- Une **moyenne (barplot)** sans **dispersion** peut cacher des différences importantes – toujours se demander ce que le résumé statistique choisi ne montre pas.
- Des **variables discrètes** sur un scatter plot créent de l’overplotting – pense au jitter et à la transparence.
- Deux variables catégorielles croisées se lisent en **tableau croisé / heatmap**, jamais en camembert à combinaisons multiples.
- Une **corrélacion** n’est jamais une preuve de **causalité**, et toute variable numérique n’a pas forcément de sens à être incluse dans une analyse (cas des ID).
- Le **camembert** est le graphe le plus souvent mal utilisé en pratique – réserve-le à 3-4 catégories très distinctes.